第二次课程作业

一. 任务

按照中国人口前 20 的城市给出两室一厅房子出租和购买的最高及最低价。

- 二. 设计思路
- 1. 选取目标网站: 58 同城
- 2. 自动生成不同城市 url
- 3. 使用 python 的 lxml 库定位价格信息
- 4. 自动获取下一页的 url
- 5. 最高价最低价获取策略:
 - (1) 比较所有页面住房的价格信息确定
 - (2) 通过网页自带价格排序功能确定
- 6. 单位不一致的情况下,需要爬取价格单位以及建筑面积等信息

三. 实验环境

- 1. 语言: python
- 2. 编译器: VSCode
- 3. 使用 python 库:

```
import requests # HTTP 库
import json
from lxml import etree # 解析库
from fake_useragent import UserAgent # 伪装请求头
import time, re, datetime
import pandas as pd
```

四. 实现步骤

1. 找到中国人口前 20 的城市列表(2019 年数据)

```
city20 = ["重庆","上海","北京","成都","天津","广州","深圳","武汉",
"南阳","临沂","石家庄","哈尔滨","苏州","保定","郑州","西安",
"赣州","邯郸","温州","潍坊"]
```

2. 找到不同城市对应的 58 同城网址特征

```
https://wh.58.com/ # 武汉 - wh
https://cd.58.com/ # 成都 - cd
```

分析可知不同城市的 58 同城首页为 https://{城市首字母缩写}.58.com/

- (1) 租房页面: https://wh.58.com/chuzu/ (武汉为例)
- (2) 买房页面: https://wh.58.com/xinfang/
- 3. 获取所有城市的名字及缩写的对应关系

目标页面: https://www.58.com/changecity.html

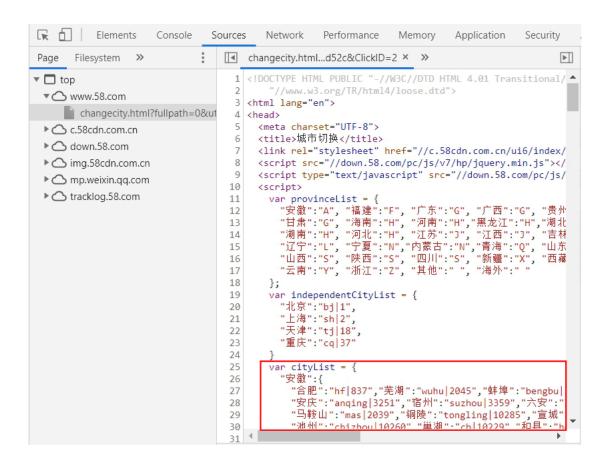
(1) 获取页面源代码

(2) 根据正则 cityList = (.*?)</script>获取相关数据

```
},
"福建":{
"福州":"fz|304","厦门":"xm|606","泉州":"qz|291","莆田":"pt|2429","漳州":"zhangzhou|710",
..
```

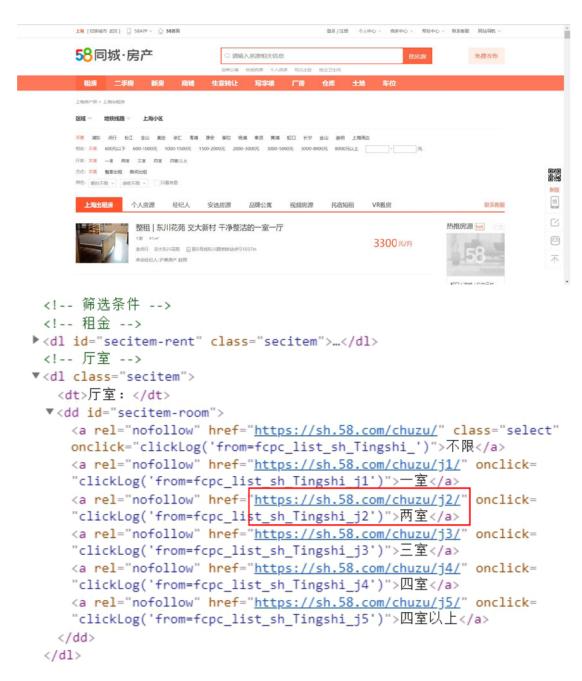
(3) 数据处理得到城市名及其缩写的词典

```
api = "https://www.58.com/changecity.html"
headers = self.session.headers.copy()
response = self.session.get(api, headers=headers)
html = response.text
res = re.findall("cityList = (.*?)</script>", html, re.S)[0]
res = re.sub("\s", "", res)
dic = json.loads(res)
for k, v in dic.items():
    or k1, v1 in v.items():
        dic[k][k1] = v1.split("|")[0]
```



4. 找到爬取租房和买房信息的关键页面

| 目的 | 条件 | url |
|----|-----------|---|
| 买房 | base_url | https://{ }.58.com/chuzu/ |
| | 筛选'二室'条件后 | https://{ }.58.com/chuzu/j2/ |
| 租房 | base_url | https://{ }.58.com/xinfang/loupan/all/ |
| | 筛选'二室'条件后 | https://{ }.58.com/xinfang/loupan/all/h2 |
| | 选择价格升序 | https://{ }.58.com/xinfang/loupan/all/h2_s2 |
| | 选择价格降序 | https://{ }.58.com/xinfang/loupan/all/h2_s1 |



```
上海58同城 > 上海房产信息 > 上海新房
        全部 河东 不熟足 青河 全山 闵行 松江 奉贤 上海周边 金山 杨河 虹口 静安 徐江 普陀 崇明 黄河 长宁 花桥
        价格: 单价 ~ 单价 ~
          全部 1.5万以下 1.5-2万 2-2.5万 2.5-3万 3-4万 4-5万 5-8万 8万以上
        户型:全部 一室 二室 三室 四室 五室及以上
        面积: 全部 60m²以下 60-90m² 90-120m² 120-150m²
        更多: 銷售状态 ~ 物业类型 ~ 开盘时间 ~ 装修状况 ~ 在售 即将开盘 近期已开 以R看房
        全部楼盘底价保障
                                                          默从非序 价格 # 开盘时间 #
                  高尚领域
                  [音陀真如]曹杨路1518号
                                                             1910 90724 TOT
                  户型: 2室/3室/4室: 建筑面积: 80-160m²
                  在售 信官 VR蓄房 项目在建 内中环 装修交付
  <!-- 户型-->
 ▼<div class="filter-item">
    <label class="item-title">户型: </label>
   ▼<div class="item-mod">
      <span>全部</span>
     ▶ <a class="multi-item" data-id="1" data-type="h" data-url="https://
     sh.58.com/xinfang/loupan/all/h1/" rel="nofollow" href="https://
     sh.58.com/xinfang/loupan/all/h1/">...</a>
     ▶<a class="multi-item" data-id="2" data-type="h" data-url="https://
    sh.58.com/xinfang/loupan/all/h2/" rel="nofollow" href="https://
    sh.58.com/xinfang/loupan/all/h2/">...</a>
     \data-id="3" data-type="h" data-url="https://
     sh.58.com/xinfang/loupan/all/h3/" rel="nofollow" href="https://
    sh.58.com/xinfang/loupan/all/h3/">...</a>
     ><a class="multi-item" data-id="4" data-type="h" data-url="https://</pre>
     sh.58.com/xinfang/loupan/all/h4/" rel="nofollow" href="https://
     sh.58.com/xinfang/loupan/all/h4/">...</a>
     ><a class="multi-item" data-id="5" data-type="h" data-url="https://</pre>
     sh.58.com/xinfang/loupan/all/h5/" rel="nofollow" href="https://
    sh.58.com/xinfang/loupan/all/h5/">...</a>
    </div>
</div>
   <a class href="https://sh.58.com/xinfang/loupan/all/h2_s2/" rel=</pre>
   nofollow">
     <del><span>价格</span></del>
     <i class="list-ico defult-down"></i></i></or>
   </a>
```

5. 构造城市租房 URL

```
''爬取租房信息的爬虫方法'''
assert self.all_city_dict is not None, "获取所有城市信息失败"
print("---all_city_dict---")
format_city = self.all_city_dict.pop(city, None)
print("format_city:", format_city)
```

```
assert format_city is not None, "{}该城市不在爬取城市之内".format(city)

'''构造该城市租房页面 url, 获取所需数据'''

self.city = city

start_url = "https://{}.58.com/chuzu/j2/".format(format_city)
```

- 6. 获取页面信息
- ▶ 通过 time.sleep(2) 来避免过于频繁的访问
- 伪装请求头来发出请求

```
ua = UserAgent()
self.session = requests.Session()
self.session.headers = {
   "user-agent": ua.random
def __get_html_source(self, url, params=None):
    '''通过 get 方式获取到网页的源码'''
   time.sleep(2)
   headers = self.session.headers.copy()
       if not params:
           params = \{\}
        response = self.session.get(url=url, headers=headers, params=params)
        return response
   except Exception as e:
        with open("./url_log_error.txt", "a", encoding="utf-8") as f:
            f.write(str(datetime.datetime.now()) + "\n")
            f.write(str(e) + "\n")
            f.write("error_url>>:{}".format(url) + "\n")
```

- 7. 从开始页面提取租房价格信息
- (1) 使用 etree 和 xpath 定位所需信息

```
▼
  <!--房源列表信息-->
 ▼<li class="house-cell " logr="gz_1_9616604916999_45417405943562_sortid:
 668167483@postdate:1616814001238" sortid="1616814001238">
   ▶ <div class="img-list">...</div>
   ▶ <div class="des">...</div>
   ▼ <div class="list-li-right">
      <div class="send-time">
                                        </div>
    ▼ <div class="money">
       <br/><br/>class="strongbox">3000</b>
        "元/月
      </div>
     (/div>
    <div class="listline"></div>
```

- (2) 通过比较确定当前页最高价以及最低价
- > xpath("string(.)")以字符串的形式取出当前标签下的值

- ▶ re.sub()去除字符串中的空白字符
- ▶ int()将字符转换为整数型
- 如果价格高于当前最高价或低于最低价,则更新最高和最低价

8. 获取下一页页面信息

查看当前页面的切换页面栏,查看元素,可知

```
def __is_exist_next_page(self, response):

'''判断是否存在下一页,存在拿到下一页的链接,不存在返回 False'''

xml = self.__response_to_xml(response)

try:

next_page_url = xml.xpath("//a[@class='next']/@href")[0]

# print(next_page_url)

return next_page_url

except IndexError:

return False
```

9. 从开始页面提取新房价格信息

- 新房页面有价格排序选项, 分别从价格升序和降序页面提取第一个房源价格即可
- 售价的单位不一致,有房屋总价,也有单位面积价格
- ▶ 有的房屋暂无售价,但给出了周边参考价

```
需要额外爬取面积信息和单位信息
   ▼<a class="favor-pos" href="https://sh.58.com/xinfang/loupan/
   59054699.html?from=AF_RANK_1" soj="AF_RANK_1" target="_blank">
    ▼
       "总价"
       <span>142</span>
       "万元/套起"
     ▼<a class="favor-pos" href="https://sh.58.com/xinfang/loupan/
59070828.html?from=AF_RANK_1" soj="AF_RANK_1" target="_blank">
   售价待定
  ▼<p class="favor-tag around-price":
                        周边均价"
    <span>145672</span>
    "元/m²
 </a>
 ▼<span class="building-area">
    ::before
    "建筑面积: 76-99m2"
  </span>
def __get_xinfang_info(self, url, params):
   response = self.__get_html_source(url, params)
   html = response.text
   # 开始从页面中提取出想要的数据
   xml = etree.HTML(html)
   # 可以定位到总价或周边定价
```

```
xpath_list = xml.xpath("//p[@class='price']/span|//p[@class='favor-tag around-price']/span
")[0]
   house_price = re.sub("\s", "", xpath_list.xpath("string(.)"))
   # <span>145672</span>"万元/套起"
   # 正则匹配单位
   unit = re.sub("<.*>", "", etree.tostring(xpath_list, encoding='UTF-8').decode()).strip()
   xpath_list = xml.xpath("//span[@class='building-area']")[0]
   area = re.sub("\s", "", xpath_list.xpath("string(.)")).split(': ')[1]
   return house_price, unit, area
```

10. 保存成文件

```
city_58 = Info_58()
zufang_list = []
xinfang_list = []
for city in city20:
    # city_58.highest = 0
```

五. 实验结果

网页有动态更新,每次爬取结果会存在差别,一下为单次爬取结果

1. 租房信息(元/月):

| 城市 | 最高价 | 最低价 |
|-----|--------|-----|
| 重庆 | 12500 | 280 |
| 上海 | 30000 | 600 |
| 北京 | 65000 | 500 |
| 成都 | 38000 | 300 |
| 天津 | 8000 | 390 |
| 广州 | 28800 | 200 |
| 深圳 | 60000 | 500 |
| 武汉 | 8000 | 300 |
| 南阳 | 17000 | 108 |
| 临沂 | 140000 | 150 |
| 石家庄 | 12000 | 350 |
| 哈尔滨 | 20000 | 180 |
| 苏州 | 24000 | 300 |
| 保定 | 20000 | 300 |
| 郑州 | 7800 | 270 |
| 西安 | 14000 | 350 |
| 赣州 | 5300 | 200 |
| 邯郸 | 20500 | 150 |
| 温州 | 45000 | 300 |
| 潍坊 | 100000 | 200 |

2. 买房信息

| 城市 | 最高价(单位) | 面积(最高) | 最低价(单位) | 面积(最低) |
|-----|-----------------|-----------------------------|------------------|---------------------------|
| 重庆 | 42000 (元/m²) | 91-340 m² | 75(万元/套起) | 64-158m² |
| 上海 | $145534(元/m^2)$ | 76-99 m² | 142(万元/套起) | 75-138m² |
| 北京 | 168000 (元/m²) | 245-443. 76m2 | 350(万元/套起) | 81. 05-131 m ² |
| 成都 | 50000(元/m²起) | 61-192 m² | 52(万元/套起) | 35-48 m² |
| 天津 | 85000(元/m²起) | 149. 78-277. 65m² | 155(万元/套起) | 79-165m² |
| 广州 | 107000 (元/m²) | 70-125m² | 560(万元/套起) | 88-131 m² |
| 深圳 | 180000 (元/m²) | 79-152m² | 1000(万元/套起) | 120-250 m² |
| 武汉 | 55000 (元/m²) | 207-300m² | 60(万元/套起) | 33-57 m² |
| 南阳 | 15000 (元/m²) | 90-140 m² | 3300 (元/ m^2) | 90-152m² |
| 临沂 | 27000(元/m²起) | 95-194m² | 5600(元/m²) | 66. 11-113. 27 m² |
| 石家庄 | 35000 (元/m²) | 99. 53-330 m² | 13090 (元/m²) | 114. 84-145. 9m² |
| 哈尔滨 | 370(万元/套起) | 88-251. 39m² | 45(万元/套起) | 42. 47-73. 39m² |
| 苏州 | 55000 (元/m²) | 113-380 m² | 44(万元/套起) | 36-69 m² |
| 保定 | 24000 (元/m²) | 49. 38-327. 2m ² | 80(万元/套起) | 80-116m ² |
| 郑州 | 30000 (元/m²) | 67. 83-136. 96m² | 350(万元/套起) | 134m² |
| 西安 | 37000 (元/m²) | 39. 13-132. 17m² | 5200 (元/m²) | 90-150 m ² |
| 赣州 | 13513(元/m²) | 95-160m² | 4900 (元/m²) | 93-142m² |
| 邯郸 | 16800 (元/m²) | 176-288m² | 1500(万元/套) | 66. 8-381 m² |
| 温州 | 44000 (元/m²) | 45-260m² | 60(万元/套起) | 57-128m² |
| 潍坊 | 16000 (元/m²) | 101-213m² | 350(万元/套起) | 103-498. 85m² |